

Clasificación de COVID-19 a partir de señales acústicas de tos

Christopher Mendoza, Alex Valdez, Piero Freundt y Diego Trujillo

*Maestría en Ciencia de Datos e Inteligencia Artificial
Universidad de Ingeniería y Tecnología (UTEC), Lima, Perú
15 de julio de 2026*

Resumen—Se aborda la clasificación binaria de COVID-19 usando únicamente el sonido de la tos, sobre un conjunto de 1357 señales (1207 negativas, 150 positivas; desbalance 8:1). Cada señal se resume en 136 descriptores acústicos extraídos con librosa. Se comparan Regresión Logística, Árboles de Decisión, KNN, SVM, MLP y ensambles de gradient boosting bajo validación cruzada estratificada, con remuestreo aplicado estrictamente dentro de cada pliegue. Se descarta el accuracy como criterio de decisión: un clasificador trivial alcanza 89% sin detectar ningún positivo. Se adopta el Macro F1. El análisis exploratorio revela que la clase positiva es bimodal: un subgrupo aislado perfectamente separable y un remanente embebido en la clase mayoritaria, lo que impone un techo estructural al recall. El sistema final, un LightGBM alimentado con descriptores clásicos, características topológicas y posteriores GMM, alcanza un Macro F1 de 0.788 en test con recall de 0.600 sobre la clase minoritaria.

Abstract—This work addresses binary COVID-19 classification using cough audio only, over 1357 signals (1207 negative, 150 positive; 8:1 imbalance). Each signal is summarized into 136 acoustic descriptors extracted with librosa. Logistic Regression, Decision Trees, KNN, SVM, MLP and gradient boosting ensembles are compared under stratified cross-validation, with resampling applied strictly within each fold. Accuracy is discarded as a decision criterion: a trivial classifier reaches 89% without detecting any positive case. Macro F1 is adopted instead. Exploratory analysis reveals the positive class is bimodal: an isolated, perfectly separable subgroup and a remainder embedded within the majority class manifold, imposing a structural ceiling on recall. The final system, a LightGBM fed with classical descriptors, topological features and GMM posteriors, reaches a test Macro F1 of 0.788 with 0.600 recall on the minority class.

Palabras clave—clasificación de audio, COVID-19, desbalance de clases, MFCC, gradient boosting, teoría de decisión.

I. INTRODUCCIÓN

La pandemia de COVID-19 evidenció la necesidad de métodos de tamizaje rápidos, no invasivos y de bajo costo. Entre las alternativas exploradas, el análisis acústico de la tos resulta atractivo: no requiere reactivos, puede ejecutarse desde un teléfono móvil y ofrece resultados en segundos. La hipótesis subyacente es que la infección altera el tracto respiratorio de forma suficiente para modificar la firma acústica de la tos.

Este trabajo evalúa esa hipótesis sobre un conjunto construido a partir de COSWARA [1] y Virufy [2], aplicando los algoritmos de clasificación clásicos (Regresión Logística, SVM, Árboles de Decisión y KNN) junto con métodos más avanzados, bajo un protocolo de validación cruzada estratificada.

El problema presenta dos dificultades que condicionan todo el diseño experimental. La primera es un desbalance de clases de aproximadamente 8:1, que invalida el accuracy como criterio de decisión: un clasificador trivial que prediga siempre la clase mayoritaria alcanza un 89% de acierto sin detectar un solo caso positivo. La segunda, revelada por el análisis exploratorio, es que la clase positiva no forma un grupo homogéneo, sino que se divide en un subgrupo acústicamente aislado y un remanente estadísticamente indistinguible de la clase negativa.

Las contribuciones de este trabajo son: (i) la caracterización empírica de la estructura bimodal de la clase minoritaria y su impacto como techo natural sobre el recall alcanzable; (ii) la demostración de que la reducción de dimensionalidad lineal (PCA y LDA) degrada el desempeño en este espacio, lo que confirma que la frontera de decisión es no lineal; (iii) la separación explícita entre inferencia y decisión siguiendo el marco de Bishop

[6], mostrando que el umbral óptimo depende de la función de pérdida y no del modelo; y (iv) un sistema final que alcanza un Macro F1 de 0.788 en test, dentro del rango que el propio análisis exploratorio anticipó como techo realista.

II. EXPLICACIÓN DE LOS MODELOS

A. Regresión Logística. Modelo lineal que estima $P(\mathcal{C}_1 | \mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x} + b)$, con $\sigma(z) = (1 + e^{-z})^{-1}$. Es lineal en las *log-odds* y se ajusta minimizando la entropía cruzada con penalización L_2 controlada por $C = \lambda^{-1}$. Sirve como línea base interpretable y como sonda de complejidad.

B. Máquinas de Vectores de Soporte. Buscan el hiperplano de máximo margen. Con margen blando, el problema es $\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_i \xi_i$ sujeto a $y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \xi_i$. El truco del kernel permite fronteras no lineales; se emplea el kernel RBF $K(\mathbf{x}, \mathbf{x}') = \exp(-\gamma \|\mathbf{x} - \mathbf{x}'\|^2)$.

C. Árboles de Decisión. Particionan recursivamente el espacio mediante umbrales sobre una característica, eligiendo en cada nodo la división que maximiza la ganancia de información $IG = I(\text{padre}) - \sum_j \frac{n_j}{n} I(\text{hijo}_j)$, con I la impureza de Gini o la entropía. Sin restricciones sobreajustan, por lo que se poda mediante `max_depth` y `min_samples_leaf`.

D. K Vecinos Más Cercanos. Clasifica por voto mayoritario entre los k ejemplos más cercanos según la distancia euclidiana. No entrena parámetros; el modelo es el propio conjunto de datos. Es altamente sensible a la escala y a la dimensionalidad del espacio de características.

Cuadro 1. Composición del vector de 136 características

Familia	Descriptor	Series
Cepstral	MFCC	13
	Delta (Δ)	13
	Delta-delta (Δ^2)	13
Espectral	Centroide	1
	Rolloff	1
	Contraste espectral	7
Armónica	Chroma STFT	12
	Tonnetz	6
Temporal	Tasa de cruces por cero	1
	Energía RMS	1
Total apilado		68
Vector final (μ y σ)		136

E. Perceptrón Multicapa. Red neuronal densa con capas ocultas y activaciones no lineales, entrenada por retropropagación. Se regulariza mediante decaimiento de pesos (L_2) y detención temprana.

F. Ensamblajes de Gradient Boosting. XGBoost [7] y LightGBM [8] construyen árboles secuencialmente, cada uno corrigiendo el residuo del anterior. Incorporan regularización explícita sobre los pesos de las hojas (λ_{L_1} , λ_{L_2}), restricciones de evidencia mínima y regularización estocástica mediante submuestreo.

III. METODOLOGÍA

A. Conjunto de datos. El conjunto contiene 1357 señales de tos: 1207 de pacientes negativos (clase 0) y 150 de pacientes positivos a COVID-19 (clase 1), con una razón de desbalance de 8.0:1. Los archivos combinan formatos .wav y .mp3; ambos se procesan de forma homogénea. Se aplica una partición estratificada 80/20 con semilla fija (random_state = 42), obteniendo 1085 muestras de entrenamiento (120 anomalías) y 272 de prueba (30 anomalías). El conjunto de prueba permanece intacto hasta la evaluación final.

B. Extracción de características. Cada señal se remuestrea a 22050 Hz y se resume en un vector de 136 dimensiones mediante librosa [4]. La metodología de extracción sigue los fundamentos de procesamiento de señales de audio para aprendizaje automático descritos en [3]. La composición se detalla en la Tabla 1: se apilan 68 series temporales y se agregan mediante media y desviación estándar a lo largo del eje temporal, lo que produce un vector de tamaño fijo independiente de la duración del clip.

C. Protocolo de validación. Todo el entrenamiento emplea validación cruzada estratificada con $K = 5$. El desbalance se trata con SMOTETomek [10]: SMOTE genera ejemplos sintéticos de la clase minoritaria mediante interpolación lineal, y los enlaces de Tomek eliminan pares de clases opuestas que son vecinos mutuos, limpiando la frontera de decisión. El remuestreo se encapsula dentro de un Pipeline de imbalanced-learn [11], garantizando que se aplique **estrictamente dentro de cada pliegue de entrenamiento** y nunca sobre los pliegues de validación ni sobre el conjunto de test. Idéntica precaución rige para el escalado y para cualquier transformación ajustada a partir de los datos.

D. Métrica de decisión. Se adopta el **Macro F1** como criterio único de selección. La justificación es cuantitativa: dado el desbalance 8:1, un clasificador que prediga siempre la clase




Figura 1. Espectrogramas Mel. Superior: clase normal. Inferior: clase positiva. La estructura acústica es visualmente similar entre clases.

mayoritaria alcanza un accuracy de 0.890 sin detectar ningún positivo, valor casi idéntico al del mejor modelo del trabajo. El Macro F1, al promediar el F1 de ambas clases con igual peso, penaliza explícitamente el fallo sobre la clase minoritaria y neutraliza ese sesgo. Se reportan adicionalmente Precision, Recall y F1 de la clase 1, así como el accuracy total exigido para la matriz de confusión final.

IV. EXPERIMENTOS Y RESULTADOS

A. Inspección cualitativa. La Fig. 1 contrasta espectrogramas Mel de ambas clases. La energía se concentra en ráfagas verticales cortas correspondientes a los golpes de tos, con una estructura acústica notablemente similar entre clases. No se aprecia un patrón visual universal que las separe, lo que justifica el recurso a descriptores estadísticos y algoritmos de aprendizaje en lugar de reglas explícitas.

B. Separabilidad no lineal. Se proyectó el espacio estandarizado de 136 dimensiones mediante t-SNE [12] y UMAP [13], empleados exclusivamente como diagnóstico visual y nunca como características de entrenamiento. La Fig. 2 revela una **dualidad geométrica**: un subgrupo compacto de anomalías completamente aislado de la distribución mayoritaria, y un remanente disperso embebido dentro de la estructura de la clase normal.

Esta observación tiene dos implicaciones directas. Primero, la frontera de decisión requiere ser altamente no lineal y fragmentada, lo que descarta aproximaciones puramente lineales. Segundo, y más relevante, la fracción de anomalías superpuesta con la clase normal impone un **techo natural al recall**: un subconjunto de casos positivos es estadísticamente indistinguible de la clase negativa en este espacio, de modo que la optimización deberá provenir de la calibración del umbral y no de memorizar el conjunto de entrenamiento.

C. Reducción de dimensionalidad. Se contrastaron PCA (no supervisado, maximiza varianza) y LDA (supervisado, maximiza separabilidad). Ambos se ajustaron exclusivamente sobre el conjunto de entrenamiento. PCA requiere 65 componentes para retener el 95% de la varianza, evidenciando una compresión pobre. LDA, al tratarse de un problema binario, colapsa a una única componente discriminante.

La Tabla 2 muestra que **ambas técnicas degradan el desempeño**. El espacio original alcanza el mejor Macro F1




Figura 2. Proyecciones t-SNE (izq.) y UMAP (der.) del espacio de 136 dimensiones. Ambas revelan un subgrupo de anomalías aislado y un remanente embebido en la clase mayoritaria.

Cuadro 2. Impacto de la reducción de dimensionalidad (sonda: Regresión Logística regularizada, CV $K = 5$)

Representación	Macro F1	$\pm$ sd	F1 (clase 1)
Sin reducción (136-D)	0.679	0.031	0.449
LDA (1 componente)	0.658	0.017	0.424
PCA (95% de varianza)	0.647	0.010	0.411

(0.679), mientras PCA cae a 0.647 y LDA a 0.658. Esto confirma empíricamente que la señal discriminante es ortogonal a las direcciones de máxima varianza: PCA descarta información estructural vital. La proyección LDA (Fig. 3, der.) evidencia que la técnica captura exitosamente el subgrupo anómalo extremo (reflejado en la pronunciada cola derecha), pero el límite lineal no resuelve el solapamiento masivo en el núcleo de la distribución. Dado que ambas son proyecciones lineales, su degradación ratifica la hipótesis del análisis exploratorio y motiva alimentar el espacio original directamente a algoritmos de partición no lineal.

D. Control de complejidad. Siguiendo a Bishop [6], el ajuste por máxima verosimilitud sin restricciones tiende al sobreajuste. Se evaluó una curva de validación variando $C = \lambda^{-1}$ en una Regresión Logística (Fig. 4). Al relajar la regularización, el desempeño en entrenamiento crece monótonamente hacia la memorización mientras la métrica de validación decae; la brecha entre ambas curvas cuantifica la varianza del modelo. El óptimo se ubica en $C \approx 10^{-1}$.

Aunque la demostración emplea un modelo lineal como sonda eficiente, el fenómeno es universal: si un modelo rígido sobreajusta severamente en este espacio de 136 dimensiones, arquitecturas más flexibles exhibirán una memorización aún más agresiva. Esto fundamenta la inclusión de hiperparámetros de regularización en el espacio de búsqueda de todas las familias evaluadas.

E. Optimización de hiperparámetros. Se empleó Optuna [9] con el algoritmo TPE, 40 trials por familia y poda por mediana. Cada trial evalúa el pipeline integral bajo validación cruzada estratificada ($K = 3$ durante la búsqueda, reservando $K = 5$ para la evaluación). La función objetivo es el Macro F1. Los resultados




Figura 3. Superior: varianza explicada por PCA y proyección 2D. Inferior: proyección LDA 1D. La clase positiva exhibe una distribución bimodal con una cola derecha separable y un núcleo solapado.

se resumen en la Tabla 3.

LightGBM obtuvo el mejor desempeño (0.766) con el menor costo computacional. La Fig. 5 muestra la historia de optimización de las tres familias.

F. Comparación de modelos. La Tabla 4 presenta la comparación central del trabajo: ocho modelos evaluados con validación cruzada estratificada $K = 5$ sobre el conjunto de entrenamiento, reportando Macro F1, F1, Precision y Recall de la clase minoritaria.

La lectura de esta tabla es más informativa que su simple ordenamiento. Los cuatro modelos superiores (MLP, Stacking, LightGBM, SVM) se ubican dentro de un margen de 0.010, indistinguible dado que las desviaciones estándar oscilan entre 0.013 y 0.042: no existe un ganador estadísticamente separado entre ellos. La jerarquía sí resulta clara respecto de los modelos




Figura 4. Curva de validación: efecto de la regularización L_2 . La divergencia entre train y validación al aumentar C cuantifica la varianza del modelo.

Cuadro 3. Optimización bayesiana (TPE, 40 trials, CV $K = 3$)

Modelo	Macro F1	Podados	Tiempo
LightGBM	0.766	25	81 s
XGBoost	0.750	8	222 s
SVM (RBF)	0.737	11	29 s

lineales y simples: la Regresión Logística (0.679), el Árbol podado (0.616) y KNN (0.530) quedan netamente por debajo, lo que confirma la naturaleza no lineal de la frontera anticipada por el análisis exploratorio.

Dos casos merecen comentario por ilustrar los extremos del compromiso precisión-recall. **KNN** exhibe el mejor recall de toda la tabla (0.817) pero la peor precisión (0.202): detecta la mayoría de los positivos a costa de generar tantas falsas alarmas que resulta inutilizable. Su bajo Macro F1 (0.530) refleja precisamente ese desequilibrio, y evidencia el efecto de la maldición de la dimensionalidad sobre un clasificador basado en distancias operando en 136 dimensiones. En el extremo opuesto, **SVM** alcanza una precisión de 0.980 (cuando afirma COVID, casi nunca se equivoca), pero con un recall de apenas 0.358. Ninguno de los dos comportamientos es aceptable para un tamizaje, y ambos justifican el uso del Macro F1 como criterio: es la única métrica de la tabla que penaliza simultáneamente ambos extremos.

G. Características adicionales. Se exploraron dos fuentes complementarias de información. La primera (Fig. 6) aplica DBSCAN [14] sobre la proyección UMAP, incorporando la pertenencia a clústeres como características topológicas. El resultado es revelador: se identifica un clúster **100% puro de anomalías** (39 de 39), mientras el clúster mayoritario mezcla 951 normales con 81 anomalías (7.8%). Esta partición cuantifica de forma exacta la dualidad geométrica anticipada: 39 de las 120 anomalías de entrenamiento son trivialmente separables; las 81 restantes están embebidas en la clase normal.

La segunda fuente modela la distribución de cada clase mediante mezclas gaussianas (GMM), seleccionando el número de componentes por BIC ($K^* = 3$ para ambas clases). El posterior GMM, empleado en solitario como clasificador, alcanza un Macro F1 de 0.733 y un AUC de 0.815, lo que confirma que aporta señal discriminante propia y justifica su inclusión como característica adicional.

Cuadro 4. Comparación de modelos bajo validación cruzada estratificada ($K = 5$), ordenados por Macro F1

Modelo	Macro F1	F1 (1)	Prec. (1)	Rec. (1)
MLP (L_2 + e.s.)	0.752	0.553	0.632	0.508
Stacking (XGB+LGBM+LR)	0.750	0.543	0.769	0.433
LightGBM (Optuna)	0.749	0.542	0.738	0.442
SVM (Optuna)	0.742	0.523	0.980	0.358
XGBoost (Optuna)	0.741	0.535	0.588	0.500
Regresión Logística (L_2)	0.679	0.449	0.369	0.575
Árbol de Decisión (podado)	0.616	0.360	0.276	0.533
KNN ($k = 5$)	0.530	0.324	0.202	0.817

Cuadro 5. Análisis de contribución (predicciones OOF, $K = 5$)

Variante	Pérdida	Macro F1	F1 (1)	AUC
Clás.+topo+GMM	log-loss	0.772	0.587	0.849
Clás.+topo	focal	0.767	0.582	0.846
Clásicas (136)	focal	0.760	0.569	0.852
Clás.+topo	log-loss	0.759	0.561	0.845
Clás.+topo+GMM	focal	0.757	0.567	0.844
Clásicas (136)	log-loss	0.751	0.546	0.852

H. Análisis de contribución. Se evaluó sistemáticamente la contribución de cada bloque de características y de la función de pérdida, comparando la entropía cruzada estándar frente a Focal Loss [15], mediante predicciones *out-of-fold* (OOF). La Tabla 5 resume los resultados.

Emergen tres hallazgos. Primero, **el enriquecimiento progresivo funciona**: partiendo de las 136 características clásicas (0.751), añadir las topológicas eleva a 0.759 y sumar el posterior GMM alcanza 0.772. Cada bloque aporta información que los anteriores no capturan.

Segundo, el comportamiento de la **Focal Loss depende de la riqueza de las características**. Sobre el conjunto clásico mejora (0.751 $\rightarrow$ 0.760) y sobre clásicas+topo también (0.759 $\rightarrow$ 0.767), pero sobre el conjunto más rico (clásicas+topo+GMM) empeora (0.772 $\rightarrow$ 0.757). La focal ayuda cuando las características son débiles y el desbalance domina, pero estorba cuando la representación ya separa razonablemente: forzar el foco en los casos difíciles introduce ruido en lugar de señal.

Tercero, la **divergencia entre AUC y Macro F1** resulta ilustrativa. Las variantes de mejor AUC (0.852, características clásicas) no son las de mejor Macro F1 (0.772, clásicas+topo+GMM). El AUC mide la separabilidad del ranking de probabilidades, mientras el Macro F1 evalúa el desempeño en el umbral operativo con ambas clases pesando por igual. Que ambas métricas no coincidan refuerza la elección del Macro F1: bajo desbalance, un buen AUC no garantiza un buen desempeño sobre la clase minoritaria.

I. Teoría de decisión y umbral. Siguiendo el marco de Bishop [6], se separa la *inferencia* (estimar $p(\mathcal{C}_1 | \mathbf{x})$) de la *decisión* (convertir probabilidades en acciones minimizando la pérdida esperada). Se define una matriz de pérdidas donde un falso negativo cuesta 100 veces más que un falso positivo:

$$L = \begin{pmatrix} 0 & 1 \\ 100 & 0 \end{pmatrix}, \quad \mathbb{E}[L] = 1 \cdot FP + 100 \cdot FN \quad (1)$$

La regla de Bayes que minimiza el riesgo decide $\mathcal{C}_1$ cuando $p(\mathcal{C}_1 | \mathbf{x}) > L_{01}/(L_{01} + L_{10}) = 1/101 \approx 0.0099$, valor muy lejano




Figura 5. Historia de optimización de Optuna (TPE) para las tres familias de modelos. La línea roja indica el mejor valor acumulado.




Figura 6. Clustering topológico UMAP + DBSCAN. Se identifica un clúster 100% puro de anomalías (39/39), mientras el remanente permanece embebido en la clase mayoritaria.




Figura 7. Barrido empírico del umbral bajo la matriz de costos 100:1. El mínimo de riesgo colapsa hacia “inspeccionar todo”; el punto de operación de máximo Macro F1 se sitúa en $t = 0.416$.

al umbral por defecto de 0.5. Dado que las probabilidades de un modelo real no están perfectamente calibradas, el umbral se barre **empíricamente sobre las probabilidades OOF**, contando errores reales (Fig. 7).

El resultado más revelador es la **sensibilidad al ratio de costos** (Tabla 6). Con 5:1 el umbral óptimo es 0.150 y mantiene un equilibrio real. Al llegar a 50:1 el sistema colapsa: $t^* \rightarrow 0$, marcando todo como anomalía para no perder ningún positivo. La transición no es gradual sino abrupta, y ocurre entre 20:1 y 50:1. Bajo costos 100:1 el mínimo empírico (riesgo 956) es prácticamente idéntico al de inspeccionar todo, lo que constituye la decisión racional que impone esa matriz de costos y no un fallo del clasificador.

Se demuestra así empíricamente la tesis de Bishop: **el umbral**

Cuadro 6. Sensibilidad del umbral óptimo al ratio de costos FN:FP (sobre probabilidades OOF)

Ratio FN:FP	t^*	FP	FN
5:1	0.150	66	43
10:1	0.039	177	26
20:1	0.013	295	20
50:1	0.000	956	0
100:1	0.000	956	0

Cuadro 7. Evaluación final en test (272 muestras, 30 anomalías)

Punto de operación	t	Macro F1	Prec. (1)	Rec. (1)	FN
Mínimo riesgo	0.000	0.113	0.112	1.000	0
Máx. Macro F1	0.416	0.788	0.643	0.600	12

óptimo no es una propiedad del modelo sino de la función de pérdida. El mismo clasificador opera en $t \approx 0$ o en $t = 0.416$ según el costo asignado al error. El umbral por defecto de 0.5 nunca fue la respuesta correcta en ninguno de los dos escenarios.

J. Evaluación final en test. El modelo campeón (LightGBM con log-loss sobre características clásicas + topológicas + GMM) se reentrenó con todo el conjunto de entrenamiento y se evaluó **una sola vez** sobre el conjunto de test, en los dos puntos de operación definidos exclusivamente a partir de probabilidades OOF. La Tabla 7 y la Fig. 8 resumen los resultados.

En el punto de operación de máximo Macro F1 ($t = 0.416$), el sistema alcanza un **Macro F1 de 0.788**, con una matriz de confusión que clasifica correctamente el **95.9%** de las muestras normales y el **60.0%** de las anomalías, con una precisión de 0.643 sobre la clase minoritaria y únicamente 10 falsos positivos frente a 12 falsos negativos. El **accuracy total** de este modelo sobre el conjunto de test es de **91.9%**.

El panel izquierdo de la Fig. 8 ilustra el colapso anticipado: bajo la matriz de costos 100:1 el modelo detecta el 100% de las anomalías (ningún falso negativo) al precio de marcar como anomalía el 98.8% de las muestras normales. El Macro F1 resultante (0.113) es deliberadamente bajo: no mide calidad de discriminación sino el costo de una política que prioriza no perder ningún positivo por encima de todo.

K. Blending y seed bagging. Como intento de superar el techo del modelo individual, se promediaron las probabilidades de los tres mejores combos del análisis de contribución, reforzando cada uno con *seed bagging* de cinco semillas (15 modelos en total).




Figura 8. Matrices de confusión en porcentajes sobre el conjunto de test. Izq.: umbral de mínimo riesgo (colapso por diseño del costo). Der.: umbral de máximo Macro F1, punto de operación reportado.




Figura 9. Matriz de confusión del ensemble (blend de 3 combos $\times$ 5 semillas). Pese a mejorar en OOF, el ensemble degradó en test respecto del modelo individual.

El resultado es negativo y merece reportarse: aunque el blend **mejoró en OOF** (0.780 frente a 0.772 del campeón individual), **degradó en test** (0.748 frente a 0.788). La matriz de confusión del blend (Fig. 9) muestra un recall superior (63.3% frente a 60.0%) pero a costa de una caída de precisión (0.500 frente a 0.643).

La explicación más plausible es la varianza del conjunto de test: con solo 30 anomalías, cada falso negativo desplaza el recall en 3.3 puntos, de modo que una ganancia OOF de 0.008 no es suficiente para transferir de forma confiable. En consecuencia, **se reporta el modelo individual como sistema final del trabajo**, y el ensemble se documenta como una vía explorada que no superó a la línea base.

V. DISCUSIÓN

El resultado central de este trabajo no es únicamente el Macro F1 de 0.788, sino la caracterización del límite que lo explica. El análisis exploratorio anticipó, mediante t-SNE, UMAP y LDA de forma independiente, una estructura bimodal en la clase positiva. El clustering con DBSCAN la cuantificó de manera exacta: 39 de las 120 anomalías de entrenamiento forman un clúster 100% puro y trivialmente separable, mientras las 81 restantes permanecen embebidas en el *manifold* de la clase normal. Ese reparto explica el recall observado: el sistema captura con facilidad el subgrupo aislado y recupera solo parcialmente el remanente solapado.

Esta interpretación se sostiene en la convergencia de evidencia independiente. La reducción de dimensionalidad

lineal degradó el desempeño en ambas variantes (PCA y LDA). Los cuatro modelos superiores de la Tabla 4 se agrupan dentro de un margen indistinguible pese a pertenecer a familias algorítmicas muy distintas (una red neuronal, un ensemble apilado, gradient boosting y SVM). El enriquecimiento con características topológicas y generativas produjo mejoras marginales y decrecientes. Y el ensemble final, pese a mejorar en validación, no transfirió. Que estrategias tan diversas topen contra el mismo rango de desempeño constituye evidencia de que la limitación no proviene de un modelado insuficiente, sino de la estructura intrínseca de los datos.

Debe subrayarse que un recall de 0.600 implica que dos de cada cinco casos positivos no serían detectados. En un escenario de tamizaje real este tipo de error es particularmente costoso, y por ello el resultado debe entenderse como una limitación sustantiva del enfoque basado exclusivamente en audio. El presente trabajo constituye un ejercicio de clasificación con fines académicos y no una herramienta de diagnóstico apta para aplicación clínica.

A. Limitaciones. El conjunto de test contiene únicamente 30 anomalías, por lo que diferencias de Macro F1 inferiores a aproximadamente 0.05 entre configuraciones cercanas no resultan estadísticamente distinguibles; un solo falso negativo desplaza el F1 de la clase 1 en cerca de 0.02. Adicionalmente, una fracción de las señales de la clase minoritaria corresponde a tomas repetidas de un número reducido de sujetos, lo que bajo partición aleatoria podría inflar levemente las métricas: una evaluación con partición por grupos de sujeto constituiría el número honesto para esta limitación. Finalmente, el conjunto combina las fuentes COSWARA y Virufy, con posible variabilidad de dispositivo y condiciones de grabación no atribuible a la condición médica.

B. Trabajo futuro. Se identifican cuatro líneas. La incorporación de *embeddings* profundos preentrenados, como YAMNet [16], podría capturar texturas acústicas que los descriptores estadísticos omiten; la infraestructura para esta rama está implementada en el repositorio, aunque su ejecución quedó fuera del alcance de este trabajo. La ampliación del número de muestras positivas resulta la palanca de mayor impacto potencial, dado que ningún método de remuestreo sintético sustituye la falta de ejemplos reales. La incorporación de información clínica adicional podría explicar los casos acústicamente ambiguos mejor que cualquier característica extraíble del sonido. Por último, la validación contra un conjunto externo permitiría confirmar si el subgrupo indistinguible es una propiedad real del problema o un artefacto de este conjunto en particular.

VI. CONCLUSIONES

Se abordó la clasificación de COVID-19 a partir de señales acústicas de tos como un problema binario fuertemente desbalanceado (8:1), bajo un protocolo estricto de validación cruzada estratificada con remuestreo confinado a los pliegues de entrenamiento.

El sistema final consiste en un LightGBM optimizado con Optuna, alimentado con 136 descriptores clásicos enriquecidos con características topológicas (UMAP+DBSCAN) y posteriores GMM. Alcanzó un **Macro F1 de 0.788** en el conjunto de test, con recall de 0.600 y precisión de 0.643 sobre la clase minoritaria, y un accuracy total de 91.9%. La transferencia entre la estimación OOF (0.787) y el desempeño en test (0.788) fue prácticamente

exacta, lo que respalda la ausencia de fuga de información.

Respecto de qué modelos ofrecen los mejores resultados, la evidencia es inequívoca en un sentido y matizada en otro. Los modelos no lineales superan claramente a los lineales y simples: MLP (0.752), Stacking (0.750), LightGBM (0.749) y SVM (0.742) se ubican muy por encima de la Regresión Logística (0.679), el Árbol de Decisión (0.616) y KNN (0.530). Sin embargo, entre los cuatro superiores las diferencias caen dentro del ruido de la validación cruzada, por lo que no existe un ganador estadísticamente separado; la selección final del LightGBM se sustenta en su superioridad al integrar las características adicionales y en su costo computacional notablemente menor.

La elección de métrica resultó determinante. Un clasificador trivial que prediga siempre la clase mayoritaria obtiene un accuracy de 0.890, valor casi idéntico al del sistema final pese a no detectar un solo positivo. Únicamente el Macro F1 discrimina el desempeño real, lo que confirma que bajo desbalance severo es la única métrica que refleja la capacidad sobre la clase de interés.

La separación entre inferencia y decisión clarificó los puntos de operación: se demostró que el umbral óptimo depende de la función de pérdida y no del modelo. Bajo una matriz de costos 100:1 el sistema colapsa racionalmente hacia “inspeccionar todo” (recall = 1 por diseño del costo), mientras que el punto de operación reportado ($t = 0.416$) equilibra precisión y sensibilidad.

Finalmente, la evidencia convergente de múltiples estrategias independientes (reducción de dimensionalidad, enriquecimiento de características, ensamblado) topando contra el mismo rango de desempeño, junto con la cuantificación exacta mediante DBSCAN de que solo 39 de 120 anomalías son trivialmente separables, sugiere que el sistema opera cerca del límite intrínseco del problema con la información disponible en el audio.

REPRODUCIBILIDAD

El código fuente completo se encuentra disponible en: <https://github.com/pierofreundt/Machine-Learning-Project-Classification-sound-signals-of-Covid-19>

Todos los experimentos emplean la semilla SEED = 42, fijada en la partición estratificada, en los pliegues de validación cruzada, en el remuestreo SMOTETomek, en el muestreador TPE de Optuna y en todos los clasificadores que la admiten, permitiendo la replicación exacta de los resultados reportados.

REFERENCIAS

- [1] N. Sharma *et al.*, “Coswara — A database of breathing, cough, and voice sounds for COVID-19 diagnosis,” en *Proc. INTERSPEECH*, 2020, pp. 4811–4815.
- [2] G. Chaudhari *et al.*, “Virufy: Global applicability of crowdsourced and clinical datasets for AI detection of COVID-19 from cough,” *arXiv:2011.13320*, 2020.
- [3] V. Velardo, “Audio Signal Processing for Machine Learning,” The Sound of AI, serie de video en línea. Disponible: <https://www.youtube.com/playlist?list=PL-wATfeyAMNqIee7cH3q1bh4QJFAaeNv0>
- [4] B. McFee *et al.*, “librosa: Audio and music signal analysis in Python,” en *Proc. 14th Python in Science Conf.*, 2015, pp. 18–25.
- [5] F. Pedregosa *et al.*, “Scikit-learn: Machine learning in Python,” *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011.
- [6] C. M. Bishop, *Pattern Recognition and Machine Learning*. New York, NY, USA: Springer, 2006.
- [7] T. Chen y C. Guestrin, “XGBoost: A scalable tree boosting system,” en *Proc. 22nd ACM SIGKDD*, 2016, pp. 785–794.

- [8] G. Ke *et al.*, “LightGBM: A highly efficient gradient boosting decision tree,” en *Adv. Neural Inf. Process. Syst.*, vol. 30, 2017, pp. 3146–3154.
- [9] T. Akiba *et al.*, “Optuna: A next-generation hyperparameter optimization framework,” en *Proc. 25th ACM SIGKDD*, 2019, pp. 2623–2631.
- [10] N. V. Chawla *et al.*, “SMOTE: Synthetic minority over-sampling technique,” *J. Artif. Intell. Res.*, vol. 16, pp. 321–357, 2002.
- [11] G. Lemaître, F. Nogueira y C. K. Aridas, “Imbalanced-learn: A Python toolbox to tackle the curse of imbalanced datasets in machine learning,” *J. Mach. Learn. Res.*, vol. 18, no. 17, pp. 1–5, 2017.
- [12] L. van der Maaten y G. Hinton, “Visualizing data using t-SNE,” *J. Mach. Learn. Res.*, vol. 9, pp. 2579–2605, 2008.
- [13] L. McInnes, J. Healy y J. Melville, “UMAP: Uniform manifold approximation and projection for dimension reduction,” *arXiv:1802.03426*, 2018.
- [14] M. Ester *et al.*, “A density-based algorithm for discovering clusters in large spatial databases with noise,” en *Proc. 2nd KDD*, 1996, pp. 226–231.
- [15] T.-Y. Lin *et al.*, “Focal loss for dense object detection,” en *Proc. IEEE ICCV*, 2017, pp. 2980–2988.
- [16] J. F. Gemmeke *et al.*, “Audio Set: An ontology and human-labeled dataset for audio events,” en *Proc. IEEE ICASSP*, 2017, pp. 776–780.
- [17] S. Davis y P. Mermelstein, “Comparison of parametric representations for monosyllabic word recognition in continuously spoken sentences,” *IEEE Trans. Acoust., Speech, Signal Process.*, vol. 28, no. 4, pp. 357–366, 1980.